Εργαστήριο 03: Φύλλο Εργασίας Φοιτητή

Τμήμα Επιστήμης Διαιτολογίας-Διατροφής · Χαροκόπειο Πανεπιστήμιο Αθηνών

ΕΡΓΑΣΤΗΡΙΟ 03 - ΦΥΛΛΟ ΕΡΓΑΣΙΑΣ

Ονοματεπώνυμο: **ΑΜ:** **Ημ/νία:**

Δεδομένα, ποιότητα & περιγραφική ανάλυση σε λογιστικό φύλλο. Δουλεύουμε **μόνο** με το πλασματικό σύνολο δεδομένων (κωδικοί P01…).

Το φύλλο εργασίας είναι υποχρεωτικό σε κάθε εργαστήριο. Το υποβάλλετε μέσω e-class **έως την Παρασκευή, 23:55**. Εκπρόθεσμα γίνεται δεκτό έως την Κυριακή, 23:55· μετά δεν γίνεται δεκτό.

ΠΡΟΘΕΡΜΑΝΣΗ

Σημειώστε **μία** απάντηση σε κάθε ερώτηση.

1. Γιατί τα δεδομένα υγείας θεωρούνται «ευαίσθητα»;

- ☐ Επειδή είναι κυρίως αριθμοί και η επεξεργασία τους είναι δύσκολη.
- ☐ Επειδή αποκαλύπτουν την υγεία ενός προσώπου και μια διαρροή μπορεί να το βλάψει (ειδική κατηγορία στον GDPR).
- ☐ Επειδή ανήκουν στο νοσοκομείο και όχι στον ασθενή.
- ☐ Επειδή αλλάζουν συχνά και παλιώνουν γρήγορα.

2. Ποιο είναι παράδειγμα «κακού» δεδομένου (garbage in);

- ☐ Βάρος ενήλικα 72 kg.
- ☐ Ύψος ενήλικα 17 cm.
- ☐ Ηλικία 45 έτη.
- ☐ Ο κωδικός P03 στη θέση του ονόματος.

ΕΡΓΑΛΕΙΑ - ΑΝΟΙΞΤΕ ΤΑ

Πόρος	
Υπολογιστικό φύλλο της σελίδας των φύλλων εργασίας (https://spitoglou.github.io/ge1400-worksheets/), ή Excel / LibreOffice Calc / Google Sheets	☐
Αρχείο `diatrofika_dedomena_deigma.csv` (φορτώνεται μόνο του στο υπολογιστικό φύλλο της σελίδας· και στο e-class)	☐

ΑΣΚΗΣΗ 1 - Σχεδιασμός φόρμας

Συμπληρώστε τον πίνακα σχεδιασμού: σε κάθε γραμμή λείπει **είτε η μονάδα είτε ένα λογικό εύρος**.

Πεδίο	Τύπος	Μονάδα	Λογικό εύρος
ID (κωδικός)	κείμενο	-	Pxx
Ηλικία	αριθμός	έτη	
Φύλο	κατηγορία	-	Α / Γ
Βάρος	αριθμός		30 - 250
Ύψος	αριθμός	cm	
Περιφέρεια μέσης	αριθμός		50 - 180
Ενέργεια	αριθμός	kcal	

Γιατί κωδικός αντί ονόματος; (σημειώστε μία)

- ☐ Για να πιάνει λιγότερο χώρο ο πίνακας.
- ☐ Για να μη φαίνεται ποιος είναι ο ασθενής: ψευδωνυμοποίηση και ελαχιστοποίηση δεδομένων.
- ☐ Επειδή το υπολογιστικό φύλλο δεν δέχεται ελληνικούς χαρακτήρες.
- ☐ Για να ταξινομούνται οι γραμμές αλφαβητικά.

ΑΣΚΗΣΗ 2 - Οργάνωση δεδομένων

- ☐ Άνοιξα το CSV· εμφανίζεται σε **7 στήλες**.
- ☐ Επιβεβαίωσα «tidy»: μία μεταβλητή/στήλη, ένας ασθενής/γραμμή.
- ☐ Πάγωσα την πρώτη γραμμή.

Πόσες γραμμές δεδομένων υπάρχουν (εκτός επικεφαλίδας);

ΑΣΚΗΣΗ 3 - Περιγραφικά μέτρα & γράφημα

Για τη στήλη **Βάρος_kg**, γράψτε τον τύπο σε ένα κενό κελί και σημειώστε το αποτέλεσμα:

Μέτρο	Τύπος	Αποτέλεσμα
Μέσος	`=AVERAGE(D2:D17)`	
Διάμεσος	`=MEDIAN(D2:D17)`	
Τυπική απόκλιση	`=STDEV.S(D2:D17)`	

Μέτρο	Τύπος	Αποτέλεσμα
Ελάχιστο	`=MIN(D2:D17)`	
Μέγιστο	`=MAX(D2:D17)`	

- ☐ Έφτιαξα **γράφημα** (ιστόγραμμα/ραβδόγραμμα) του βάρους.

Προχωρημένη: στήλη ΔΜΣ `=Βάρος/(Ύψος/100)^2`. Πόσοι έχουν ΔΜΣ>30;

ΑΣΚΗΣΗ 4 - Έλεγχος ποιότητας

Ελέγξτε το αρχείο και σημειώστε **τα τέσσερα** που είναι πραγματικά προβλήματα ποιότητας:

- ☐ **P01:** δεν υπάρχει το όνομα του ασθενούς.
- ☐ **P03:** ενέργεια 2450 kcal, τιμή αδύνατη για ενήλικα.
- ☐ **P05:** εμφανίζεται δύο φορές (διπλότυπο).
- ☐ **P07:** ύψος 17 cm, πιθανό λάθος πληκτρολόγησης ή μονάδας.
- ☐ **P10:** λείπει η περιφέρεια μέσης (missing).
- ☐ **P12:** βάρος 145 kg, ακραία τιμή (outlier).
- ☐ **P14:** ηλικία 58 έτη, εκτός λογικού εύρους.

Ερώτηση κριτικής σκέψης: Το βάρος 145 kg το διαγράφετε αμέσως; (σημειώστε μία)

- ☐ Ναι· κάθε ακραία τιμή είναι λάθος και διαγράφεται.
- ☐ Ναι· αλλιώς ο μέσος όρος βγαίνει μεγαλύτερος.
- ☐ Όχι· πρώτα ελέγχεται (πηγή, ΔΜΣ, άλλες μετρήσεις), γιατί μπορεί να είναι πραγματική τιμή.
- ☐ Όχι· τα δεδομένα μιας μελέτης δεν αλλάζουν ποτέ.

ΟΛΟΚΛΗΡΩΜΕΝΗ ΑΣΚΗΣΗ

Φτιάξτε ένα «καθαρό» αντίγραφο και τεκμηριώστε τις αλλαγές:

- ☐ Διόρθωσα το ύψος του **P07** (υπόθεση: _____ cm) · σημείωσα την αλλαγή.
- ☐ Αφαίρεσα το διπλότυπο **P05**.
- ☐ Σημείωσα το missing (**P10**) · επισήμανα το outlier (**P12**).

Μετά το καθάρισμα - Βάρος: Μέσος = _____ Διάμεσος = _____

Ποιο συμπέρασμα στηρίζεται στα αποτελέσματα μετά το καθάρισμα; (σημειώστε μία)

- ☐ Ο μέσος είναι μεγαλύτερος από τη διάμεσο, γιατί η ακραία τιμή του P12 τον «τραβά» προς τα πάνω.
- ☐ Ο μέσος και η διάμεσος συμπίπτουν, άρα δεν υπάρχουν ακραίες τιμές.
- ☐ Η διάμεσος επηρεάζεται από την ακραία τιμή περισσότερο από τον μέσο.
- ☐ Όλοι οι συμμετέχοντες έχουν φυσιολογικό βάρος.

Γιατί κρατάμε ίχνος (log) των αλλαγών μας; (σημειώστε μία)

- ☐ Για να μπορεί κάποιος να ελέγξει και να επαναλάβει τι αλλάξαμε και γιατί.
- ☐ Για να μεγαλώνει το αρχείο με χρήσιμες πληροφορίες.
- ☐ Επειδή το απαιτεί το υπολογιστικό φύλλο.
- ☐ Για να μη χρειαστούμε ξανά το αρχικό αρχείο.

ΑΥΤΟΑΞΙΟΛΟΓΗΣΗ

- ☐ Οργανώνω δεδομένα κατά «tidy data».
- ☐ Υπολογίζω περιγραφικά μέτρα σε υπολογιστικό φύλλο.
- ☐ Εντοπίζω missing, outliers, σφάλματα, διπλότυπα.
- ☐ Εξηγώ γιατί χρησιμοποιούμε ανωνυμοποιημένα δεδομένα.

EXIT TICKET (παραδώστε πριν φύγετε)

1. Μέσος **ή** διάμεσος με ένα ακραίο βάρος 145 kg - ποιο & γιατί;

2. Ένα πράγμα που **δυσκολεύτηκα** στο υπολογιστικό φύλλο:

3. Μία αρχή GDPR που εφάρμοσα σήμερα:

ΠΡΟΕΤΟΙΜΑΣΙΑ ΓΙΑ ΔΙΑΛΕΞΗ 4

- ☐ Μελετήστε τις σημειώσεις της Διάλεξης 3 (e-class).
- ☐ Σκεφτείτε: πώς «ταξιδεύει» η πληροφορία ενός ασθενούς μέσα σε ένα νοσοκομείο;

Προσωπικές σημειώσεις

Βοήθεια: Forum e-class · pitoglou@hua.gr