Διάλεξη 3: Μέθοδοι Ανάλυσης Δεδομένων - Σημειώσεις

Τμήμα Επιστήμης Διαιτολογίας-Διατροφής · Χαροκόπειο Πανεπιστήμιο Αθηνών

Διάλεξη 3 - Σημειώσεις

Μέθοδοι Ανάλυσης Δεδομένων - από τα δεδομένα στη γνώση Αντιστοίχιση με το κύριο σύγγραμμα (Αποστολάκης & Βαρλάμης): Κεφ. 2 «Συστήματα Βάσεων Δεδομένων» (2.2, 2.4, 2.6), Κεφ. 7.8 «Ευρωπαϊκός κανονισμός Προστασίας Προσωπικών Δεδομένων και Υγεία». Αντιστοίχιση με σύγγραμμα (Μαντάς & Χάσμαν, συμπληρωματικό): Κεφ. 2.1 (Data Analysis Methods).

Μαθησιακοί στόχοι

Να διακρίνετε τύπους δεδομένων και μεθόδους συλλογής, να αξιολογείτε την ποιότητα ενός συνόλου δεδομένων, να υπολογίζετε/ερμηνεύετε βασικά περιγραφικά μέτρα, να εφαρμόζετε βασικές αρχές GDPR, και να κρίνετε τα όρια της αυτοματοποιημένης/AI ανάλυσης.

1. Υπενθύμιση DIKW

Το μοντέλο **Δεδομένα -> Πληροφορία -> Γνώση -> Σοφία** (Διάλεξη 1) είναι ο συνδετικός ιστός. Η διάλεξη αυτή εστιάζει στα δύο πρώτα σκαλιά: πώς **συλλέγουμε** ποιοτικά δεδομένα και πώς τα μετατρέπουμε σε **πληροφορία** μέσα από οργάνωση και ανάλυση. Η ποιότητα κάθε απόφασης εξαρτάται από την ποιότητα του πρώτου κιόλας δεδομένου.

2. Τύποι δεδομένων

Διακρίνουμε **ποσοτικά** (συνεχή, π.χ. βάρος 72,4 kg· διακριτά, π.χ. αριθμός γευμάτων) από **ποιοτικά/κατηγορικά** (ονομαστικά, π.χ. φύλο· διατεταγμένα, π.χ. επίπεδο δραστηριότητας). Επίσης **δομημένα** (πίνακες) από **αδόμητα** (ελεύθερες σημειώσεις). Ο τύπος καθορίζει τι ανάλυση επιτρέπεται (π.χ. μέσος όρος έχει νόημα σε αριθμητικά, όχι σε ονομαστικά).

3. Σχεδιασμός μελετών

Οι **ποσοτικές** μελέτες μετρούν («πόσο; πόσοι;»), οι **ποιοτικές** ερμηνεύουν εμπειρίες («γιατί; πώς;»)· συχνά συνδυάζονται (μεικτές μέθοδοι).

4. Συλλογή και οργάνωση δεδομένων

Πηγές: μετρήσεις (ανθρωπομετρία, εργαστηριακά), ερωτηματολόγια/ιστορικό, ημερολόγια τροφής, ΗΦΥ, φορητές συσκευές. Η **αυτο-αναφορά** είναι πρακτική αλλά επιρρεπής σε σφάλμα (οι άνθρωποι υποεκτιμούν την πρόσληψη). Μια **καλή φόρμα συλλογής** έχει σαφή πεδία με μονάδες, ελέγχους εγκυρότητας (εύρη, υποχρεωτικά), τυποποιημένες κατηγορίες (dropdown) και **μοναδικό αναγνωριστικό-κωδικό αντί ονόματος**.

Η οργάνωση ακολουθεί την αρχή **«tidy data»**: μία μεταβλητή ανά στήλη, μία παρατήρηση (ασθενής)

ανά γραμμή, μία τιμή ανά κελί. Η μονάδα γράφεται στην επικεφαλίδα της στήλης, όχι μέσα στο κελί: «Ηλικία (έτη)», «Βάρος (kg)», «Ύψος (cm)», και από κάτω σκέτοι αριθμοί. Καλή δομή σήμερα σημαίνει λιγότερο καθάρισμα αύριο.

5. Ποιότητα και ακεραιότητα δεδομένων

Αξιολογούμε ένα σύνολο δεδομένων σε πέντε διαστάσεις: **πληρότητα** (λείπουν τιμές;), **ακρίβεια** (σωστές μετρήσεις;), **συνέπεια** (ίδιες μονάδες/μορφή;), **εγκυρότητα** (λογικές τιμές εντός εύρους;) και **επικαιρότητα**. Ο κανόνας «garbage in, garbage out» είναι απόλυτος: καμία εξελιγμένη ανάλυση δεν διορθώνει κακά δεδομένα. Τυπικά σφάλματα στη διατροφή: ύψος 17,8 αντί 178 cm (μονάδες), κενά πεδία, αδύνατες τιμές ΔΜΣ (outliers), διπλοκαταχωρίσεις. Αντιμετώπιση: έλεγχοι εύρους στη φόρμα, εντοπισμός missing/outliers, καθαρισμός πριν την ανάλυση.

6. Προστασία δεδομένων και ηθική - GDPR

Τα δεδομένα υγείας είναι **ειδική κατηγορία («ευαίσθητα»)** προσωπικών δεδομένων και ο GDPR απαιτεί αυξημένη προστασία. Βασικές αρχές που αφορούν άμεσα τον διαιτολόγο:

- **Νόμιμη βάση & συναίνεση:** επεξεργαζόμαστε δεδομένα με νόμιμη βάση, ενημερώνοντας το άτομο.
- **Ελαχιστοποίηση & σκοπός:** συλλέγουμε μόνο ό,τι χρειάζεται, για συγκεκριμένο σκοπό.
- **Ασφάλεια & πρόσβαση «need to know»:** ασφαλής αποθήκευση, περιορισμένη πρόσβαση.

Διακρίνουμε **ψευδωνυμοποίηση** από **ανωνυμοποίηση**.

- **Ψευδωνυμοποίηση:** τα στοιχεία ταυτότητας αντικαθίστανται από κωδικό, και το «κλειδί» αντιστοίχισης φυλάσσεται χωριστά· η διαδικασία είναι αναστρέψιμη. Ο ΓΚΠΔ το λέει ρητά (αιτιολογική σκέψη 26): «Τα δεδομένα προσωπικού χαρακτήρα που έχουν υποστεί ψευδωνυμοποίηση, η οποία θα μπορούσε να αποδοθεί σε φυσικό πρόσωπο με τη χρήση συμπληρωματικών πληροφοριών, θα πρέπει να θεωρούνται πληροφορίες σχετικά με ταυτοποιήσιμο φυσικό πρόσωπο.» Παραμένουν δηλαδή **προσωπικά δεδομένα**, και τα δεδομένα υγείας παραμένουν **ειδικής κατηγορίας**, με όλη την προστασία.
- **Ανωνυμοποίηση:** δεν αρκεί να αφαιρεθεί το όνομα ή να καταστραφεί το κλειδί. Ηλικία, φύλο, περιοχή και μια σπάνια διάγνωση μαζί μπορεί να αρκούν για να βρεθεί το πρόσωπο. Τα ίδια τα δεδομένα μετασχηματίζονται: **συνάθροιση** (π.χ. μέσος ΔΜΣ ανά ηλικιακή ομάδα αντί για μία γραμμή ανά ασθενή), **γενίκευση** (ηλικία σε ομάδες 40-49 αντί για 43), αφαίρεση σπάνιων τιμών. Ο στόχος είναι να ελαχιστοποιηθεί η πιθανότητα να συνδεθούν τα δεδομένα ξανά με φυσικό πρόσωπο, ακόμη και με διασταύρωση με άλλες πηγές. Μόνο τα πραγματικά ανώνυμα δεδομένα βγαίνουν έξω από τον κανονισμό.

Κανόνας του μαθήματος: στα εργαστήρια χρησιμοποιούμε **μόνο ανωνυμοποιημένα ή πλασματικά δεδομένα** και κωδικούς (P01, P02…), ποτέ πραγματικά δεδομένα ασθενών. (Επιστρέφουμε αναλυτικά στον GDPR στη Διάλεξη 11.)

7. Δύο τρόποι συλλογισμού

Ο **παραγωγικός** συλλογισμός πηγαίνει από γενικό κανόνα σε ειδικό συμπέρασμα (ΔΜΣ>30 -> παχυσαρκία -> ο ασθενής με 32 είναι παχύσαρκος). Ο **επαγωγικός** πηγαίνει από παρατηρήσεις σε γενίκευση/υπόθεση (στο δείγμα, υψηλή ζάχαρη συνοδεύει υψηλό ΔΜΣ). Και οι δύο είναι χρήσιμοι - αλλά η επαγωγική γενίκευση χρειάζεται επιβεβαίωση.

8. Περιγραφική στατιστική & EDA

Τα **μέτρα θέσης** (μέσος, διάμεσος, επικρατούσα) και **διασποράς** (εύρος, τυπική απόκλιση, min/max) συνοψίζουν ένα σύνολο n τιμών $x_1, x_2, \dots, x_n$:

- **Μέσος:** $\bar{x} = \dfrac{\sum x_i}{n}$, το άθροισμα όλων των τιμών διά το πλήθος τους.
- **Διάμεσος:** η μεσαία τιμή μετά την ταξινόμηση· για άρτιο n, ο μέσος των δύο μεσαίων.
- **Επικρατούσα:** η συχνότερη τιμή.
- **Εύρος:** max — min.
- **Τυπική απόκλιση (δείγματος):** $s = \sqrt{\dfrac{\sum (x_i - \bar{x})^2}{n-1}}$, η «τυπική» απόσταση μιας τιμής από τον μέσο. Στο λογιστικό φύλλο είναι η συνάρτηση `STDEV.S`.

Κρίσιμη ιδέα: όταν υπάρχουν **outliers**, ο μέσος «τραβιέται» και η **διάμεσος** περιγράφει καλύτερα. Η **Διερευνητική Ανάλυση Δεδομένων (EDA)** - πίνακες συχνοτήτων, ιστογράμματα, θηκογράμματα - μας κάνει να «γνωρίσουμε» τα δεδομένα (κατανομή, ακραίες τιμές, ελλείψεις) **πριν** βγάλουμε συμπεράσματα.

Παράδειγμα: για ΔΜΣ {21,23,24,25,26,27,29,31,45}, ο μέσος (~27,9) επηρεάζεται από το 45, ενώ η διάμεσος (26) είναι πιο αντιπροσωπευτική· το 45 είναι πιθανό outlier που πρέπει να ερευνηθεί (λάθος καταχώρισης ή πραγματικό ακραίο).

9. AI & αυτοματοποιημένη ανάλυση (κριτική ματιά)

Εργαλεία τεχνητής νοημοσύνης συνοψίζουν και εντοπίζουν μοτίβα/outliers γρήγορα, αλλά: μαθαίνουν από τα δεδομένα μας (κακά δεδομένα -> μεροληπτικά αποτελέσματα), μπορεί να παρουσιάζονται «σίγουρα» ενώ σφάλλουν (χρειάζεται πάντα **επαλήθευση**), και η ευθύνη παραμένει στον επαγγελματία («**human in the loop**»). Θέμα προς εμβάθυνση στη Διάλεξη 11.

Σύνδεση με το εργαστήριο

Το Εργαστήριο 3 εστιάζει σε μία δεξιότητα: σχεδιασμός φόρμας, οργάνωση πλασματικού συνόλου δεδομένων σε λογιστικό φύλλο, υπολογισμός περιγραφικών μέτρων και ένα γράφημα, και έλεγχος ποιότητας (missing/outliers).

Βιβλιογραφία

- Αποστολάκης Ι., Βαρλάμης Η. (2020). *Πληροφοριακά Συστήματα Υγείας*, 4η έκδ., Εκδ. Παπαζήση - **Κεφ. 2 «Συστήματα Βάσεων Δεδομένων» (2.2, 2.4, 2.6), Κεφ. 7.8 «Ευρωπαϊκός κανονισμός Προστασίας Προσωπικών Δεδομένων και Υγεία»**. *(κύριο σύγγραμμα, ΕΥΔΟΞΟΣ)*
- Μαντάς Ι., Χάσμαν Α. (2007). *Πληροφορική της Υγείας* - **Κεφ. 2.1**. *(συμπληρωματικό)*
- Αρχή Προστασίας Δεδομένων Προσωπικού Χαρακτήρα - https://www.dpa.gr/
- USDA FoodData Central - https://fdc.nal.usda.gov/

Σημεία για την εξέταση

- Πέντε διαστάσεις ποιότητας δεδομένων, με παράδειγμα (σύντομη απάντηση).
- Μέσος vs διάμεσος παρουσία outlier - ποιο και γιατί (κριτική σκέψη).
- Ψευδωνυμοποίηση vs ανωνυμοποίηση· γιατί τα δεδομένα υγείας είναι «ευαίσθητα» (ανάπτυξη).
- Ένας περιορισμός της AI στην ανάλυση δεδομένων υγείας (κριτική σκέψη).