ΜΕΘΟΔΟΙ ΑΝΑΛΥΣΗΣ ΔΕΔΟΜΕΝΩΝ

Διάλεξη 3

Από τα δεδομένα στη γνώση - συλλογή, ποιότητα, EDA

ΓΕ1400 - Εφαρμογές Πληροφορικής σε Επαγγέλματα Υγείας | Εξάμηνο Α΄

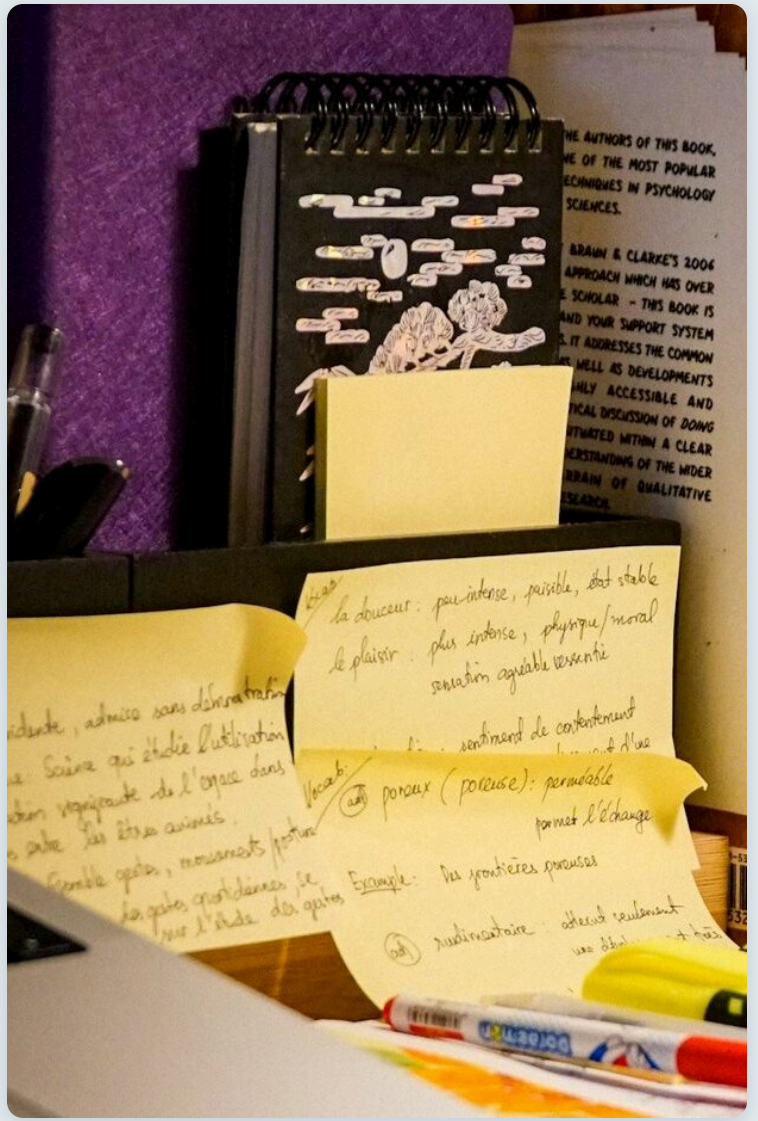
Τμήμα Επιστήμης Διαιτολογίας-Διατροφής · Χαροκόπειο Πανεπιστήμιο

Dr. Σταύρος Πιτόγλου

Μαθησιακοί Στόχοι

Μετά την ολοκλήρωση αυτής της διάλεξης, θα είστε σε θέση να:

1. **Διακρίνετε** τύπους δεδομένων υγείας και τρόπους συλλογής τους.
2. **Αξιολογείτε** την ποιότητα & ακεραιότητα ενός συνόλου δεδομένων.
3. **Υπολογίζετε & ερμηνεύετε** βασικά περιγραφικά μέτρα (EDA).
4. **Εφαρμόζετε** βασικές αρχές προστασίας δεδομένων (GDPR) στην πράξη.
5. **Κρίνετε** τον ρόλο & τα όρια της αυτοματοποιημένης/AI ανάλυσης.



Περιεχόμενα

1. Υπενθύμιση DIKW
2. Τι είναι τα δεδομένα - τύποι
3. Σχεδιασμός μελετών (ποσοτικές/ποιοτικές)
4. Συλλογή & οργάνωση δεδομένων
5. **Ποιότητα & ακεραιότητα**
6. **Προστασία δεδομένων & ηθική**
7. **Περιγραφική στατιστική & EDA**
8. AI στην ανάλυση · εργαστήριο

📖 Αντιστοίχιση με σύγγραμμα: Αποστολάκης & Βαρλάμης **Κεφ. 2** (Βάσεις Δεδομένων), **Κεφ. 7.8** (GDPR και Υγεία) · Μαντάς & Χάσμαν **Κεφ. 2.1** (Data Analysis Methods).



Υπενθύμιση: Το Μοντέλο DIKW

Αυτή η διάλεξη εστιάζει στα **δύο πρώτα σκαλιά**: πώς **συλλέγουμε** ποιοτικά δεδομένα και πώς τα μετατρέπουμε σε **πληροφορία** με ανάλυση.

💡 Καλή απόφαση = καλή αλυσίδα από το πρώτο κιόλας δεδομένο.



Σε αυτή τη διάλεξη: τα δύο πρώτα σκαλιά

Τι Είναι τα Δεδομένα - Τύποι

Διάκριση	Είδη	Παράδειγμα (διατροφή)
Ποσοτικά	Συνεχή / Διακριτά	Βάρος 72,4 kg · αριθμός γευμάτων 4
Ποιοτικά (κατηγορικά)	Ονομαστικά / Διατεταγμένα	Φύλο · επίπεδο δραστηριότητας (χαμηλό→υψηλό)
Δομή	Δομημένα / Αδόμητα	Πίνακας μετρήσεων · ελεύθερες σημειώσεις

Ο τύπος του δεδομένου καθορίζει **πώς** θα το αναλύσουμε.



Σχεδιασμός Μελετών

Ποσοτικές

Μετρήσιμα δεδομένα, αριθμοί, στατιστική. «Πόσο; Πόσοι;»

Ποιοτικές

Εμπειρίες, νόημα, συνεντεύξεις. «Γιατί; Πώς;»

Συχνά συνδυάζονται (μεικτές μέθοδοι).



Συλλογή Δεδομένων Υγείας

Πηγές

- Μετρήσεις (ανθρωπομετρία, εργαστηριακά)
- Ερωτηματολόγια & ιστορικό
- Ημερολόγια τροφής
- ΗΦΥ / συσκευές

Μέθοδοι

- Άμεση παρατήρηση/μέτρηση
- Αυτο-αναφορά (προσοχή στο bias)
- Δομημένες φόρμες

⚠ Η αυτο-αναφορά (self-report) υποεκτιμά συχνά την πρόσληψη - μια πηγή σφάλματος.



Σχεδιασμός Καλής Φόρμας Συλλογής

- **Σαφή πεδία** με τύπο & μονάδες (kg, cm, kcal).
- **Έλεγχοι εγκυρότητας** (εύρη τιμών, υποχρεωτικά πεδία).
- **Τυποποιημένες κατηγορίες** (dropdown αντί ελεύθερου κειμένου).
- **Μοναδικό αναγνωριστικό** (κωδικός, όχι όνομα).

🔍 Καλή φόρμα σήμερα = λιγότερος καθαρισμός δεδομένων αύριο. (Το φτιάχνετε στο εργαστήριο.)

Νέο περιστατικό

Κωδικός ασθενούς *

P07

✓ μοναδικός κωδικός, όχι όνομα

Βάρος *

82,0 kg

✓ αριθμός, με μονάδα

Ύψος *

178 cm

✓ εύρος 100-230

Επίπεδο δραστηριότητας *

Μέτριο ▾

✓ λίστα, όχι ελεύθερο κείμενο

* υποχρεωτικό πεδίο

Οργάνωση Δεδομένων: «Tidy Data»

- Μία **μεταβλητή** ανά στήλη
- Μία **παρατήρηση** (ασθενής) ανά γραμμή
- Μία τιμή ανά κελί · η μονάδα στην επικεφαλίδα, όχι στο κελί

ID	Ηλικία (έτη)	Βάρος (kg)	Ύψος (cm)
P01	45	82	178
P02	39	61	165

⊗ Κοινό λάθος: πολλές τιμές σε ένα κελί ή στήλες με μπερδεμένες μονάδες.



μία τιμή ανά κελί, ίδιες μονάδες παντού

Ποιότητα & Ακεραιότητα Δεδομένων

Διάσταση	Ερώτηση
Πληρότητα	Λείπουν τιμές (missing);
Ακρίβεια	Είναι σωστές οι μετρήσεις;
Συνέπεια	Ίδιες μονάδες & μορφή παντού;
Εγκυρότητα	Είναι λογικές οι τιμές (εύρη);
Επικαιρότητα	Είναι ενημερωμένα;

«Garbage in, garbage out»: **καμία** ανάλυση δεν διορθώνει κακά δεδομένα.



Garbage in, garbage out

Σφάλματα Δεδομένων στη Διατροφή

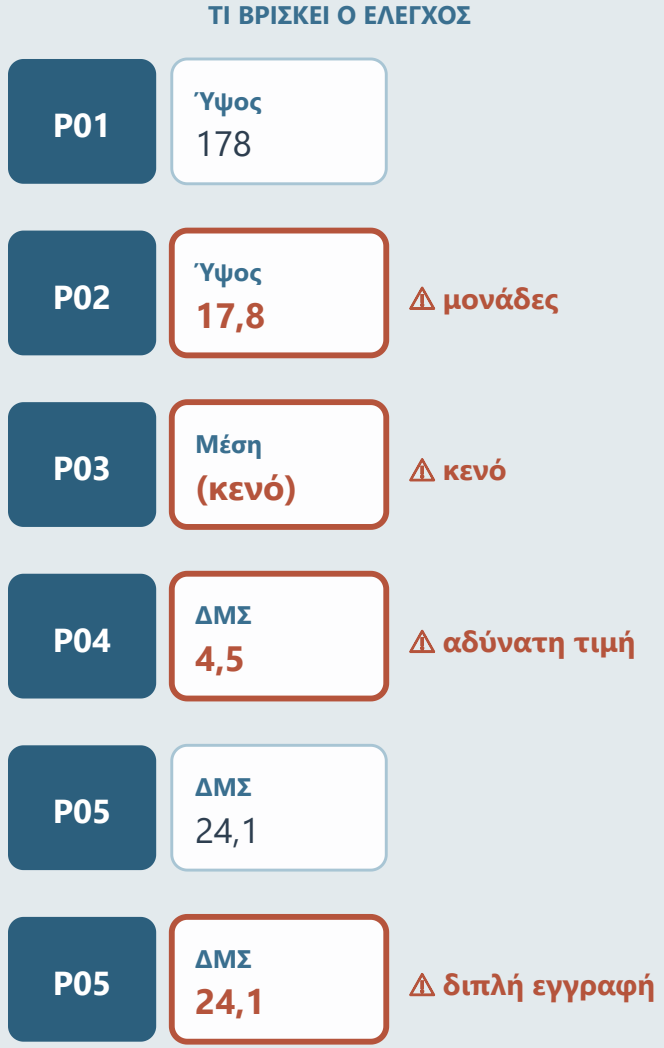
Παραδείγματα σφαλμάτων

- Ύψος 17,8 αντί 178 cm (μονάδες)
- Κενό πεδίο περιφέρειας μέσης
- ΔΜΣ 4,5 (αδύνατη τιμή → outlier)
- Διπλοκαταχώριση ασθενούς

Αντιμετώπιση

- Έλεγχοι εύρους στη φόρμα
- Εντοπισμός missing & outliers
- Καθαρισμός πριν την ανάλυση

Αυτά ακριβώς θα τα εντοπίσετε στο σύνολο δεδομένων του εργαστηρίου.



Προστασία Δεδομένων & Ηθική (GDPR)

Τα δεδομένα υγείας είναι **ειδική κατηγορία («ευαίσθητα»)** προσωπικών δεδομένων - απαιτούν αυξημένη προστασία (GDPR).

Νόμιμη βάση

Συναίνεση / έννομη υποχρέωση· ενημέρωση του ατόμου.

Ελαχιστοποίηση

Συλλέγω μόνο ό,τι χρειάζομαι, για συγκεκριμένο σκοπό.

Ασφάλεια

Πρόσβαση «need to know», ασφαλής αποθήκευση.

⚠ Στο μάθημα: **ποτέ πραγματικά δεδομένα ασθενών** - μόνο ανωνυμοποιημένα/πλασματικά.



Ανωνυμοποίηση vs Ψευδωνυμοποίηση

	Τι κάνει	Παράδειγμα
Ψευδωνυμοποίηση	Αντικαθιστά τα στοιχεία ταυτότητας με κωδικό· το «κλειδί» φυλάσσεται χωριστά	Μαρία Π. → **P07** (με ξεχωριστό πίνακα αντιστοίχισης)
Ανωνυμοποίηση	Μετασχηματίζει τα δεδομένα (**συνάθροιση**, **γενίκευση**, αφαίρεση σπάνιων τιμών) ώστε να μην μπορούν να συνδεθούν ξανά με φυσικό πρόσωπο	Μέσος ΔΜΣ ανά ηλικιακή ομάδα (40-49 ετών, n = 38) αντί για μία γραμμή ανά ασθενή

ΓΚΠΔ, αιτ. σκέψη 26: «Τα δεδομένα προσωπικού χαρακτήρα που έχουν υποστεί ψευδωνυμοποίηση [...] θα πρέπει να θεωρούνται πληροφορίες σχετικά με ταυτοποιήσιμο φυσικό πρόσωπο.» Παραμένουν δηλαδή **προσωπικά δεδομένα**, και τα δεδομένα υγείας παραμένουν **ειδικής κατηγορίας**.

Ο στόχος της ανωνυμοποίησης: να ελαχιστοποιηθεί η πιθανότητα να «ξαναβρεθεί» το πρόσωπο, ακόμη και με διασταύρωση με άλλες πηγές. Στο εργαστήριο: **πλασματικά** δεδομένα με κωδικούς (P01, P02...).



Δύο Τρόποι Συλλογισμού

Παραγωγικός (deductive)

Από γενικό κανόνα → ειδικό συμπέρασμα.

«ΔΜΣ>30 = παχυσαρκία· ο ασθενής έχει 32 → παχύσαρκος.»

Επαγωγικός (inductive)

Από παρατηρήσεις → γενίκευση/ υπόθεση.

«Στο δείγμα, υψηλή πρόσληψη ζάχαρης συνοδεύει υψηλό ΔΜΣ.»



Περιγραφική Στατιστική

Μέτρα θέσης

- **Μέσος** (mean): $\bar{x} = \Sigma x_i \,/\, n$
- **Διάμεσος** (median): η μεσαία τιμή μετά την ταξινόμηση· για άρτιο n, ο μέσος των δύο μεσαίων · ανθεκτική σε outliers
- **Επικρατούσα** (mode): η συχνότερη τιμή

Μέτρα διασποράς

- **Εύρος** (range): $max - min$
- **Τυπική απόκλιση** (SD, δείγμα): $s = \sqrt{[\, \Sigma(x_i - \bar{x})^2 \,/\, (n-1)\,]}$
- Ελάχιστο / Μέγιστο

Όταν υπάρχουν **outliers**, η **διάμεσος** περιγράφει καλύτερα από τον μέσο.



Διερευνητική Ανάλυση Δεδομένων (EDA)

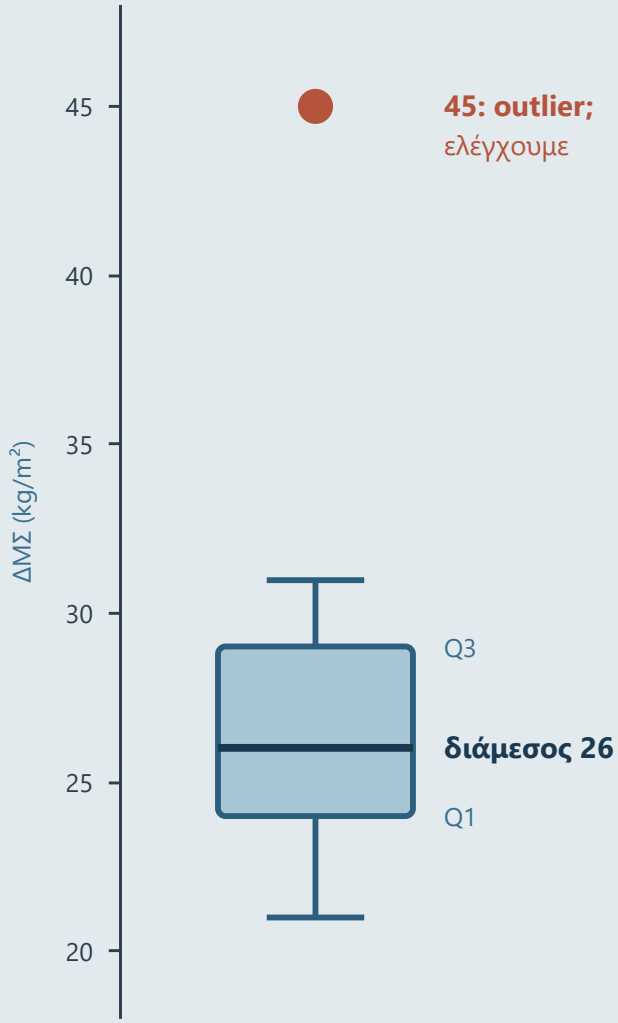
«Γνωρίζω τα δεδομένα μου πριν βγάλω συμπεράσματα.»

Εργαλεία EDA

- Πίνακες συχνοτήτων
- Ιστόγραμμα / ραβδόγραμμα
- Θηκόγραμμα (boxplot) για outliers

Τι ψάχνω

- Κατανομή & κέντρο
- Ακραίες τιμές
- Ελλείψεις (missing)

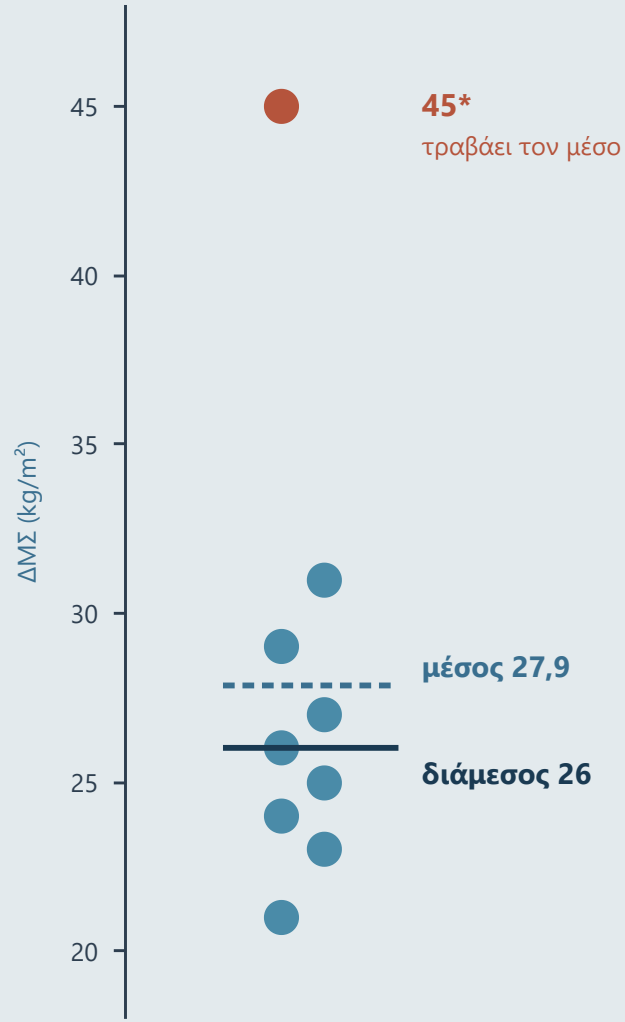


Παράδειγμα EDA (Διατροφή)

Δείγμα ΔΜΣ (kg/m²): 21, 23, 24, 25, 26, 27, 29, 31, 45*

Μέτρο	Τιμή	Σχόλιο
Μέσος	27,9	«τραβιέται» από το 45
Διάμεσος	26	πιο αντιπροσωπευτική
Μέγιστο	45*	πιθανός **outlier** - έλεγχος!

🔍 Το 45 μπορεί να είναι λάθος καταχώρισης ή πραγματικό ακραίο - **το ερευνούμε**.

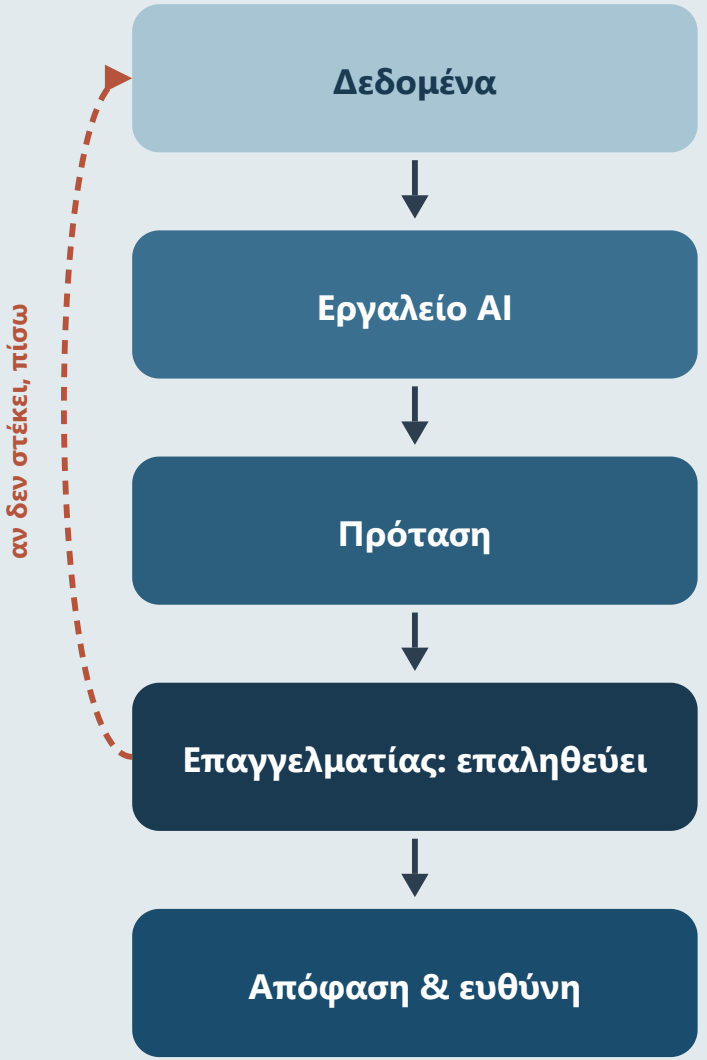


AI & Αυτοματοποιημένη Ανάλυση

Κριτική ματιά: Εργαλεία AI μπορούν να συνοψίζουν, να εντοπίζουν μοτίβα και outliers γρήγορα - αλλά:

- ⓘ Μαθαίνουν από τα δεδομένα μας: **κακά δεδομένα → κακά αποτελέσματα & bias**.
- ⓘ Μπορεί να «σιγουρεύονται» ενώ σφάλλουν - **επαληθεύουμε πάντα**.
- ✓ Ο επαγγελματίας κρατά την ευθύνη: **«human in the loop»**.

Επανερχόμαστε στην AI (τάσεις & ηθική) στη Διάλεξη 11.



Εφαρμογές στη Διατροφική Πράξη & Έρευνα

- **Κλινική:** παρακολούθηση δεικτών ασθενούς στον χρόνο.
- **Έρευνα:** ανάλυση διατροφικών ερευνών & παρεμβάσεων.
- **Δημόσια υγεία:** διατροφικά δεδομένα πληθυσμού.
- **Ποιότητα:** δείκτες & audit υπηρεσιών διατροφής.

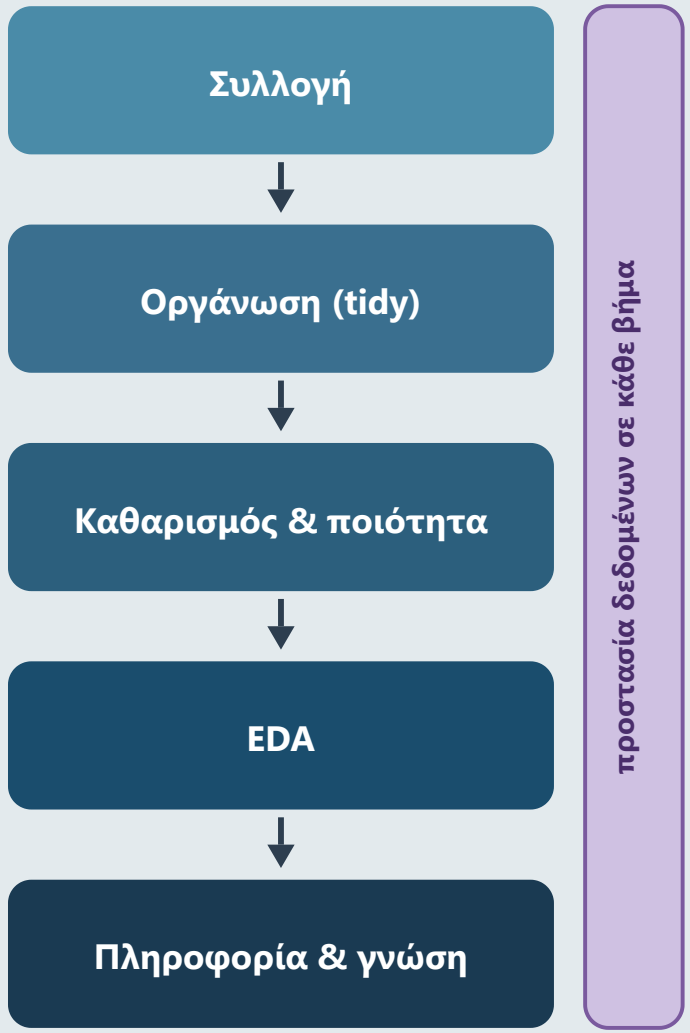
> 💡 Όλα ξεκινούν από **ποιοτικά, καλά οργανωμένα, νόμιμα** δεδομένα.



Η Αλυσίδα με μια Ματιά

`Συλλογή` → `Οργάνωση (tidy)` → `Καθαρισμός/ποιότητα` → `EDA` → `Πληροφορία & γνώση`

...με **προστασία δεδομένων** σε κάθε βήμα και **κριτική ματιά** στα εργαλεία.



Βασική Ορολογία

Όρος	Σημασία
Tidy data	Μία μεταβλητή/στήλη, μία παρατήρηση/γραμμή
Missing value	Ελλείπουσα τιμή
Outlier	Ακραία/ύποπτη τιμή
EDA	Διερευνητική Ανάλυση Δεδομένων
Ψευδωνυμοποίηση	Κωδικός αντί ταυτότητας (με κλειδί)

ΟΙ ΟΡΟΙ ΤΗΣ ΔΙΑΛΕΞΗΣ

Tidy data
μία μεταβλητή ανά στήλη

Missing value
ελλείπουσα τιμή

Outlier
ακραία ή ύποπτη τιμή

EDA
διερευνητική ανάλυση

Ψευδωνυμοποίηση
κωδικός αντί ταυτότητας

Το Εργαστήριο αυτής της Διάλεξης

Θα κάνουμε στο εργαστήριο

- Σχεδιασμό φόρμας συλλογής
- Οργάνωση δεδομένων (tidy, κωδικοί)
- Περιγραφικά μέτρα & γράφημα στο Excel
- Έλεγχο ποιότητας (missing/outliers)

Θα χρειαστείτε

- Excel / LibreOffice Calc / Google Sheets
- Το σύνολο δεδομένων του εργαστηρίου (ανωνυμοποιημένο)
- Φύλλο Εργασίας 3

⚠ Χρησιμοποιούμε **μόνο** ανωνυμοποιημένα/πλασματικά δεδομένα.



Βιβλιογραφία & Πηγές

Αποστολάκης Ι., Βαρλάμης Η. (2020) - *Πληροφοριακά Συστήματα Υγείας*, 4η έκδ., Εκδ. Παπαζήση. Για αυτή τη διάλεξη: **Κεφ. 2, Κεφ. 7.8**.

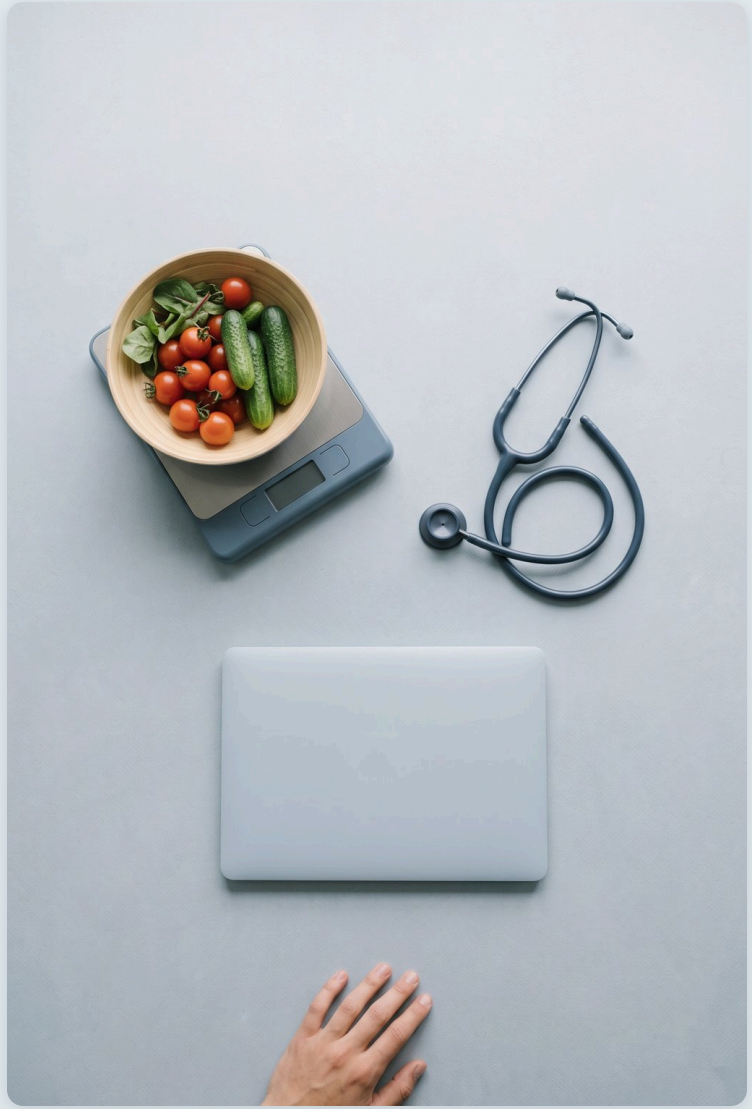
Μαντάς Ι., Χάσμαν Α. (2007) - *Πληροφορική της Υγείας*, Εκδ. Π.Χ. Πασχαλίδης. Για αυτή τη διάλεξη: **Κεφ. 2.1**.

- Αρχή Προστασίας Δεδομένων Προσωπικού Χαρακτήρα (ΑΠΔΠΧ): https://www.dpa.gr/
- USDA FoodData Central: https://fdc.nal.usda.gov/
- Σημειώσεις διαλέξεων - e-class (DIET312).



Ανακεφαλαίωση

- Ο **τύπος** των δεδομένων καθορίζει την ανάλυση· η **καλή φόρμα** προλαμβάνει σφάλματα.
- **Ποιότητα δεδομένων** = πληρότητα, ακρίβεια, συνέπεια, εγκυρότητα.
- **Περιγραφική στατιστική & EDA** μετατρέπουν δεδομένα σε πληροφορία· η **διάμεσος** αντέχει τα outliers.
- **GDPR:** δεδομένα υγείας = ευαίσθητα· ελαχιστοποίηση, ασφάλεια, ανωνυμοποίηση.
- **AI:** χρήσιμη αλλά με επαλήθευση & ευθύνη του επαγγελματία.



Προετοιμασία για την Επόμενη Διάλεξη

Διάλ. 4 Πληροφοριακά Συστήματα Νοσοκομείων (ΝΠΣ)

- Μελετήστε τις σημειώσεις της Διάλεξης 3 (e-class).
- Ολοκληρώστε το Φύλλο Εργασίας του Εργαστηρίου 3.
- Σκεφτείτε: πώς «ταξιδεύει» η πληροφορία ενός ασθενούς μέσα σε ένα νοσοκομείο;

📖 Αντιστοίχιση Διάλ. 4: Αποστολάκης & Βαρλάμης Κεφ. 4 (ΠΣ Νοσοκομείων), Κεφ. 7.1-7.4 (Ασφάλεια ΠΣΥ) · Μαντάς & Χάσμαν Κεφ. 3.2 (Hospital Information Systems).

ΤΟ ΕΞΑΜΗΝΟ

1 Εισαγωγή
2
3 Ανάλυση Δεδομένων
4 Συστήματα & Γνώση επόμενη
5
6
7
8
9
10 Οργανωσιακά
11
12 Επανάληψη

Συζήτηση 💬

> Ερωτήσεις χωρίς μία σωστή απάντηση. Τέτοιου τύπου σκέψη ζητά το 20% της εξέτασης (κριτική σκέψη).

- «Τα δεδομένα δεν λένε ψέματα.» Συμφωνείτε;
- Πόσο ανώνυμα είναι πραγματικά τα «ανωνυμοποιημένα» δεδομένα υγείας;
- Ποιος ευθύνεται όταν μια λάθος καταχώριση οδηγήσει σε λάθος συμπέρασμα: αυτός που την έκανε ή αυτός που την εμπιστεύτηκε;



Ερωτήσεις;

e-class: https://eclass.hua.gr/courses/DIET312/

Email: pitoglou@hua.gr

Forum ερωτήσεων στο e-class · Απάντηση σε email εντός 48 ωρών

